

國立成功大學工程科學系
專題報告書



深度學習模型之超聲波影像血栓診斷

Deep Learning Model for Blood Clot Diagnosis from Ultrasound Imaging

作者：碩博生：曾柏諺、楊筑涵 大學專題生：林耕澤、陳鎮濃
指導教授：游濟華助理教授
計畫合作對象：成大醫院心臟內科劉秉諺醫師、陳柏偉醫師

壹、摘要:	3
貳、研究動機與目標	3
參、研究方法及步驟	4
一、了解醫師診斷之依據:	4
二、資料收集:	4
三、資料標記:	5
四、建立模型:	5
五、loss function 及衡量標準選擇:	6
六、把資料放入模型訓練測試:	7
七、調整模型及參數:	7
八、挑出品質較差的資料:	8
九、threshold 調整:	9
十、增加資料量（水平翻轉）:	10
十一、血管壓縮比率計算:	11
十二、製作 GUI:	12
肆、計畫成果	12
一、動靜脈位置預測:	12
二、圖形化介面:	13
三、靜脈面積變化率:	14
伍、未來展望	14
一、圖形化介面增進:	14
二、靜脈面積變化率判定標準:	14
三、data pipeline:	14
四、論文發表:	15
陸、整體計畫工作分配:	15
柒、參考文獻	15

壹、摘要：

在現今快速的生活步調下，患有血栓相關疾病的人數大幅上升，醫師因此承受了相當高的工作量，所以如何輔助醫生快速且有效率診斷相關疾病成為一個重要議題。

當今深部靜脈栓塞(DVT)檢查以血管超音波攝影最準確，不過血管攝影是侵入性檢查，存在著一定的風險。相對地，血管超音波是非侵入性檢查，不過超音波的判斷是主觀且非常看重醫生的經驗，因此我們想利用深度學習模型來提高利用超音波判斷血栓相關疾病效率並降低誤診率。本研究以深度學習捲積神經網路(CNN)的 Unet 與 ResNet 模型準確標記超音波圖上之動脈及靜脈位置，並計算靜脈在受壓過程中的變化情形，以作為診斷血栓的參考。在資料部分我們取得來自成大醫院 570 筆已標記之心血管超音波圖資料，將標記出的動靜脈位置作為我們訓練的資料集，再以資料集所訓練出來的深度學習模型來辨識動靜脈位置。我們的模型除了可以預測靜態的圖片中動脈及靜脈位置，也可以利用影片預測出血管在受壓前後的變化情形。同時也將研究成果結合了 GUI 介面使醫生可以即時預測影像，以幫助醫生於臨床上的診斷，也可讓非專業人員檢測深部靜脈血栓。

貳、研究動機與目標

超音波照影的診斷一般是以醫生肉眼判斷，因此是非常主觀的，但是透過機器學習和深度學習，我們可以利用量化數據和資料的方式來做到相對醫師更為客觀的診斷，並且還能藉由自動化流程的方式來節省醫師在每個病人身上花費的時間和精力，讓醫師在有限的時間內將產值拉升至最高。

為此，我們希望能利用深度學習模型預測動脈和靜脈位置，再去計算靜脈受壓前後變化程度去輔助醫生快速診斷病人是否有血栓的疑慮。


參、研究方法及步驟

一、了解醫師診斷之依據：

目前醫生診斷該病人血栓風險高低的方式是：藉由股動脈與靜脈在超音波影像下受壓的變形程度來進行判斷。若觀察到靜脈受壓時變形程度較小，則可以推測該病人的血液有阻塞的情況，也就是有血栓形成；反之，若觀察到靜脈受壓時變形程度較大，則可以推論該病人的血管沒有阻塞狀況，也就是沒有血栓形成。

二、資料收集：

我們取得來自成大醫院心臟內科劉秉諺醫師與陳柏偉醫師的 152 位病人(每位病人 2~4 張)共 570 張已標記及原圖超音波照片作為研究資料，而每位病人的超音波照影位置可能都不盡相同，因此會有不同相對位置及數量的血管照影圖，如下圖一所示。



(圖一) 股動靜脈不同位置切面圖[1]

三、資料標記：

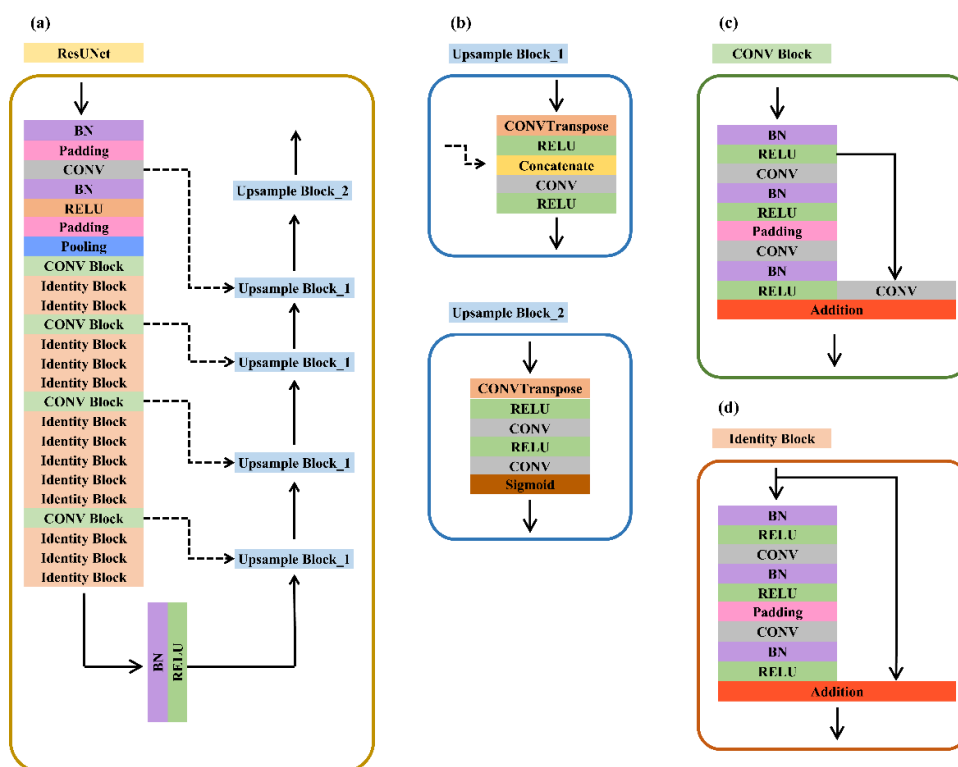
將標記的圖片中的標記單獨取出，再將圖片調整至適合的大小和座標，將裁切好的圖片整理好，並作為訓練模型的資料及做使用，如下圖（藍色為靜脈）。



(圖二) 左:原始以標記圖片 中:原始圖檔 右:單獨取出標記

四、建立模型：

我們結合了深度學習模型 ResNet 以及 U-Net 作為本次研究的模型，圖三為模型架構圖。



(圖三) 模型架構圖 (a)為主架構 (b)(c)(d)各個 Block 的架構

選用 ResNet + U-net 的原因：

ResNet: 我們將 Resnet 設置在 encoder 可避免在 downsampling 時發生梯度消失的問題，其次因為有直連通路(skip connection)與卷積層的相加，使模型只需要學習輸入與輸出之間的殘差(residual)，可以降低模型訓練難度。

U-net: 本研究的 data 為血管的超音波照片，而正常的靜脈在診斷時會因為醫師的按壓而變得非常扁平，而比較細微的特徵(例如:被按壓的靜脈)在 downsampling 時很有可能被作雜訊，所以會在過程中消失。而 U-net 的特點剛好可以彌補這個問題，U-net 會將 decoder 與 encoder 同一個 stage 以直連通路(skip connection)相連，可以將一些在 downsampling 過程中被消失掉的特徵補回來。

五、loss function 及衡量標準選擇：

本專題採用 binary cross entropy 以及 log dice loss 的結合作為 loss function，下列算式分別為 binary cross entropy 以及 log dice loss 的計算方法:(x_i : 模型預測值， \tilde{x}_i :標記值)

$$L_{BCE}(x_i, \tilde{x}_i) = -\frac{1}{N} \sum_i x_i \log(\tilde{x}_i) + (1 - x_i) \log(1 - \tilde{x}_i)$$

用於為網絡提供確定給定的輸出。

$$L_{dice}(x_i, \tilde{x}_i) = -\log \left(\frac{2\sum_i x_i \tilde{x}_i + Smooth}{\sum_i x_i + \sum_i \tilde{x}_i + Smooth} \right) [2]$$

用於觀察重疊區域，如果完全重疊則數值為一。

另外我們也使用了 dice coefficient(計算圖形重疊率) 以及 binary accuracy 來進行綜觀的效果評估。

六、把資料放入模型訓練測試：

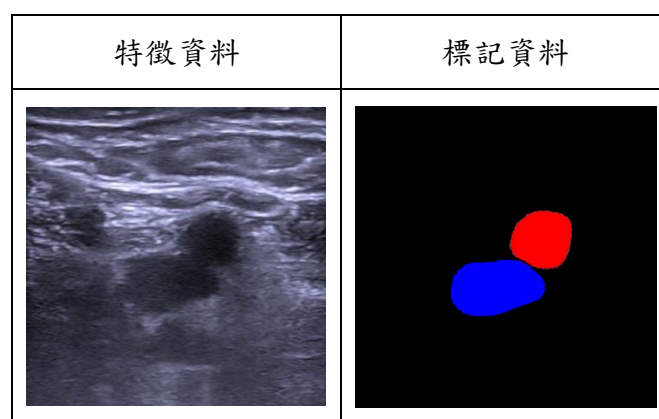
將資料集分成訓練集、驗證集、測試集。

訓練集：放入模型訓練的一筆資料。

驗證集：與訓練集一起放入模型作為訓練好壞的指標。

測試集：未放入模型訓練，測試模型的訓練成果。

	訓練集	驗證集	測試集
照片張數	428	84	58




七、調整模型及參數：

一開始我們把 learning rate 設定在 0.0001，不過出現了 overfitting(也有可能是訓練過慢的問題)：

1. 測試不同的 learning rate
2. 在 encoder 中加入 dropout layer 測試


在經過多次測試比較之後發現，當 learning rate 設定為 0.001 時可解決了此問題，如下圖。(圖片中的 test, valid 皆為驗證集、train 為訓練集)



(圖四) 左:learning rate=0.0001 loss 右:learning rate=0.001 loss

八、挑出品質較差的資料:

在經過多次調整過模型與參數後，我們發現如此的做法對於預測的成果影響還是有限的，因此我們轉將焦點著重在資料上。一開始我們的想法是將訓練結果較差的資料挑選出來(大多是照片較為模糊)，嘗試把不好的資料挑出來後再做測試，發現準確度有再提升一些，但仍然很有限。

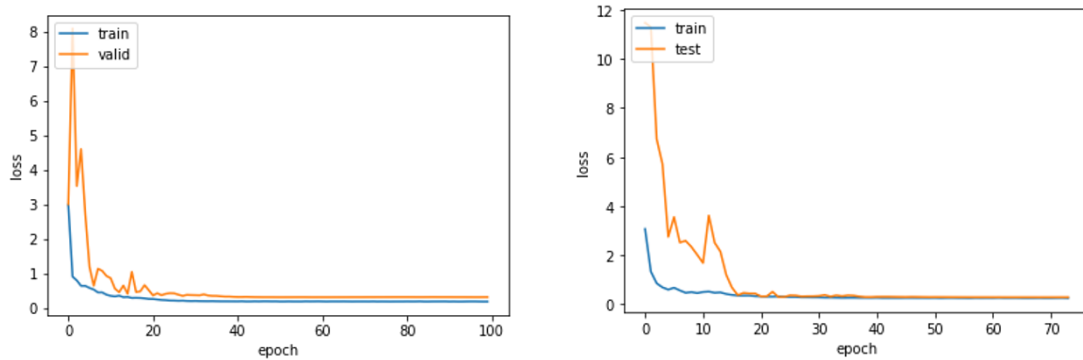


(圖五) 單靜脈預測比較 左:未挑資料 loss 右:挑資料 loss

單靜脈預測(未挑選資料、有挑選資料):

	loss	dice coefficient
訓練集 (未挑選資料)	0.4464	0.3645
訓練集 (有挑選資料)	0.3528	0.4365

驗證集（未挑選資料）	0.6514	0.2614
驗證集（有挑選資料）	0.5844	0.2757




（圖六）單動脈預測比較 左：未挑資料 loss 右：挑資料 loss

單動脈預測(未挑資料 -> 有挑資料)：


	loss	dice coefficient
訓練集（未挑選資料）	0.1858	0.8050
訓練集（有挑選資料）	0.2307	0.7705
驗證集（未挑選資料）	0.3152	0.6832
驗證集（有挑選資料）	0.2625	0.7354

九、threshold 調整：

在微調過模型後，大部分測試的結果都逐漸穩定，只是具體在圖片上的預測仍然有一些改進的空間。因此，我們後來在參數的調整上選擇從 threshold 著手。動脈的預測表現較為穩定，因此我們沒有太多的更動，主要都更著重在調整靜脈的預測模型上，而在比對過多種 threshold 的表現過後，我們選擇了有最佳表現的組合：「動脈 threshold=0.5, 靜脈 threshold=0.001」



(圖七) 動脈 threshold=0.5, 靜脈 threshold=1e-6 之預測成果



(圖八) 動脈 threshold=0.5, 靜脈 threshold=1e-3 之預測成果


十、增加資料量 (水平翻轉)：

在調整完參數過後，表現仍有進步空間，我們推測是資料量不夠造成這樣的現象。於是我們決定將所有資料做水平翻轉，讓資料量在不影響資料品質的前提下提高一倍，以此來得到較好的訓練成果。


	loss	dice coefficient
訓練集	$\doteq 0.05$	$\doteq 0.98$
驗證集	$\doteq 0.06$	$\doteq 0.97$

十一、血管壓縮比率計算：

從超音波影像中我們能觀察到靜脈在被施壓時，在正常情況下，會變得較扁平，如下列圖片所示。



(圖十) 未加壓時



(圖十一) 加壓後

不過為了量化靜脈受壓的變形程度，我們將受壓之後靜脈的截面積確切變化了多少數據轉換為數據去紀錄，以利後續的判斷進行。為此，我們引入超音波照影影片逐幀擷取圖片在進行圖片的前處理，之後再依序進入模型內預測，預測後再輸出圖計算藍色部分像素數量來計算靜脈的變化率。

下列表為(圖十)(圖十一)標記與預測結果像素個數及加壓前後變化率

	加壓前	加壓後	變化率
標記	1149	169	85.29%

預測	1423	193	86.44%
----	------	-----	--------

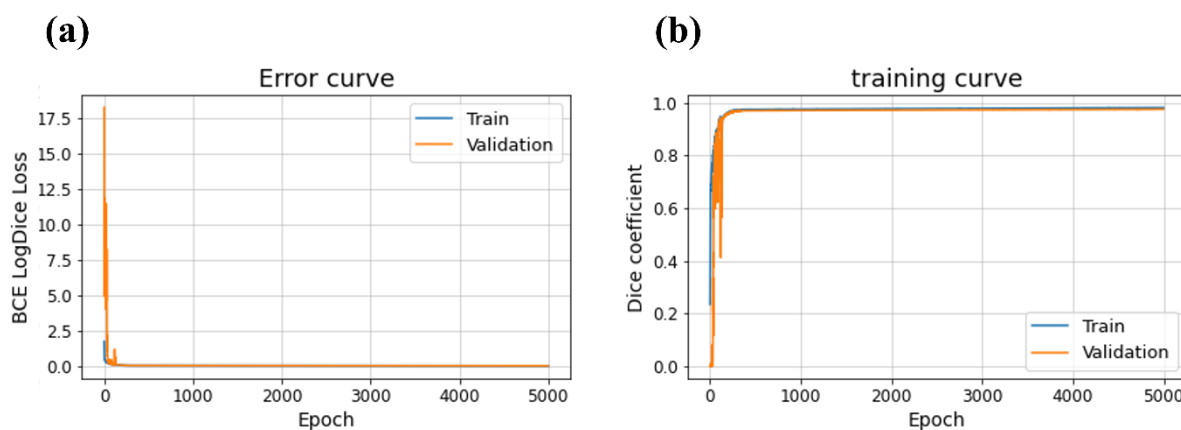
十二、製作 GUI:

最後，為了讓醫師及護理師或其他無程式基礎的醫護人員也能夠順利使用我們的成品，我們利用 tkinter 套件製作了圖形化介面將整體的運作過程包裝起來，讓使用者可以輕鬆地利用我們建立起的模型來做到偵測動靜脈的位置。在如下圖的圖形化介面中，我們可以透過選取曲內的圖片，並按下「預測」的按鈕後就可以生成該圖片動靜脈的位置預測，將整個過程已簡單易懂的方式呈現在使用者面前。

肆、計畫成果

一、動靜脈位置預測:

再經多次的調整(包含模型及資料調整)，loss 和 dice coefficient 都到達了預期的目標。



(圖九) (a)BCE Log Dice Loss (b)Dice coefficient

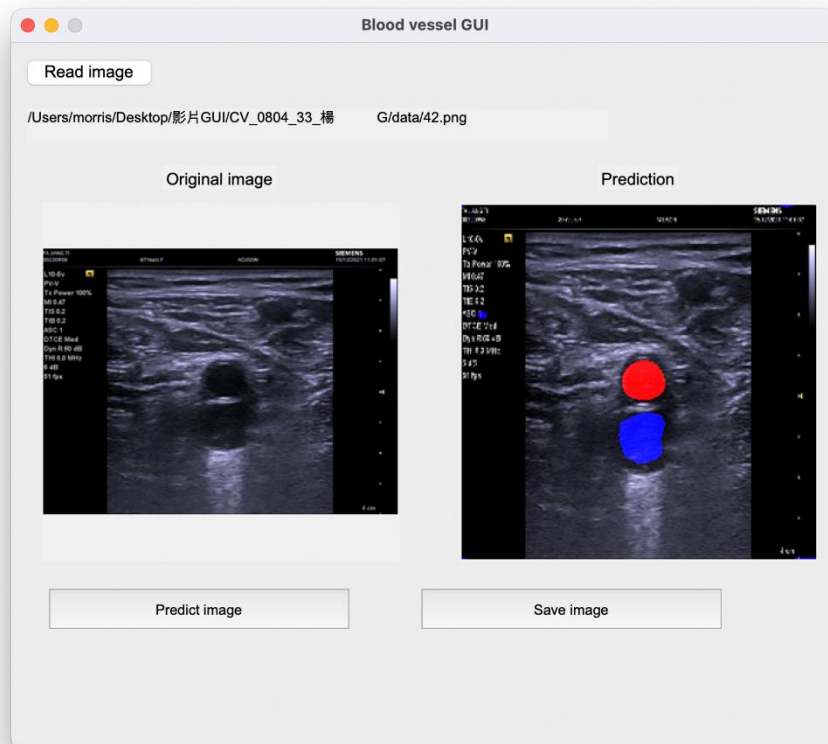
下列為經過多次調整後最終模型的 loss 和 dice coefficient

	loss	dice coefficient
訓練集	≈ 0.05	≈ 0.98
驗證集	≈ 0.06	≈ 0.97

由上表格及圖片可得知，最後的預測成果在數據有相當好的表現，並且在超音波照片上的具體預測狀況也有不錯的呈現。可以說，整體的表現算是有達到我們的預期。

二、圖形化介面：

利用 tkinter 套件來製作出醫師容易使用的圖形化介面，並且將我們訓練完成的模型導入其中，讓使用者可以匯入圖片並預測出動靜脈的位置，然後疊圖在圖片上，最後儲存疊圖後的圖片。



(圖十二) 目前 GUI 樣式

三、靜脈面積變化率：

將圖片串連起來後，能夠偵測靜脈在受壓下的面積變化率，而醫師也會依據此變化率作為判斷病人是否有血栓的依據。

伍、未來展望

目前我們成品的雖然能做到預測動靜脈的位置並測出靜脈的變化率，但還仍有數處可更加深入的改進空間以及未來的規劃，而我們也預計在未來進行優化。

一、圖形化介面增進：

目前我們所呈現的圖形化介面只能從檔案選擇圖片後，進行動靜脈的位置預測並儲存。未來我們希望讓醫師可以將影片匯入介面，並直接進行預測和變化率的偵測。

二、靜脈面積變化率判定標準：

雖然我們能夠偵測靜脈壓縮後的面積變化率，但尚未確定變化率低於多少臨界值是有血栓形成的。未來我們預計會開發另一個預測模型來學習如何訂定每個不同的病人的變化率臨界值，來幫助醫師進行更完善的診斷。

三、data pipeline:

現階段的模型需要我們手動將新的資料下載下來，並重新訓練模型以進行更新，在維護模型的步驟上是較為繁複的。未來我們會在後端建立起資料庫，並透過自動化 data pipeline 的方式來更新資料，並將新的資料餵入模型以進行訓練，讓模型能夠定期且自動地更新。

四、論文發表：

而最後，我們目前正在將此專題的研究成果撰寫為一篇論文，並投稿至中華民國力學學會年會暨第四十六屆全國力學會議(CTAM)中的人工智慧與多尺度模擬工程論壇，作為此專題研究的整體收尾。

陸、整體計畫工作分配：

(博)曾柏諺:模型建構、模型微調、技術指導

(碩)楊筑涵:模型建構、資料標記、資料整理、變化率分析

林耕澤:參數調整及測試(單靜脈、圖片水平翻轉前)、模型微調、資料挑選測試

陳鎮濃:Linux 建構相容套件環境、參數調整及測試(單動脈、圖片水平翻轉後)

柒、參考文獻

[1] Lower Extremity Deep Venous Thrombosis, Ariel L. Shiloh:

[https://eu-ireland-custom-media-prod.s3-eu-west-](https://eu-ireland-custom-media-prod.s3-eu-west-1.amazonaws.com/UKMEAEU/eSample/extraits/9780323544702-.pdf)

[1.amazonaws.com/UKMEAEU/eSample/extraits/9780323544702-.pdf](https://eu-ireland-custom-media-prod.s3-eu-west-1.amazonaws.com/UKMEAEU/eSample/extraits/9780323544702-.pdf)

[2] Diagnosing Pneumothorax in X-Ray Images Using Deep Learning, Felix Steinberger

Eriksson: <https://felixseriksson.github.io/papers/rayspaper.pdf>

UNet+ResNet34 in keras, Siddhartha:

<https://www.kaggle.com/code/meaninglesslives/unet-resnet34-in-keras>